

我的建议：

提前一晚上的准备时间配置好TRAE CURSOR之类的IDE，注意使用的是linux系统，所以提前准备好安装文件，不然用网页版的AI根本做不完。

有些大模型微调的题目在训练集上微调一轮就可能要一个小时，安排好题目时间分配。四个题目。可能只有一两个是微调

考前须知

1. 本场考试只允许使用发放的专用笔记本电脑，不得使用任何其他电子设备。
2. 考试期间，如有任何问题，可举手示意，向在场监考老师求助。监考老师视情况回答。若考生的问题涉及到本场考试的考察内容范围，监考老师将选择不回答该问题。
3. 每位考生均分配到一台专用虚拟开发机，开发机上有一张 **NVIDIA A100** 显卡用于模型训练及预测，显存为 80G。请使用命令 `ssh dev` 访问开发机资源。可自行配置 VS Code 远程访问开发机。
4. 考试需要的所有文件都在开发机上挂载的远端只读目录 `/vepfs-readonly/` 下。
5. 在开发机上挂载的 `/vepfs/` 为每个考生的专属目录（可读写），用于存储答题过程中额外产生的代码、环境、模型 checkpoint 文件、数据等其他文件。
6. 每题的题目描述中均有一个提交内容部分，请严格按照该部分的指令提交每道题评分需要的文件到专属目录 `/vepfs/` 中。
7. 考生与监考老师确认后，可以提前结束考试。离场前，须将试卷等考试资料上交给监考老师，不得带出考场。离场后不得在考场附近逗留或交谈。
8. 禁止公开发布与本场考试有关的任何内容。如经发现，学院有权进行追究。

秋季营 - 科研实训其中一个

题目：蛋白质溶解性预测

题目背景与目标

给定一个已经训练好的 **ESM-100M** 预训练模型 (checkpoint)，目标是在此基础上构建蛋白溶解性预测的完整微调流程。

该任务要求理解溶解性预测的生物学与工程背景，设计合理的输入与输出形式与损失函数，并通过标准评测指标在提供的测试集上达到稳定且可复现的性能。

蛋白质溶解性是衡量蛋白在水溶环境中保持单体、避免聚集的能力，与蛋白的表达产率、可纯化性、以及下游结构研究密切相关。模型的输入为蛋白的氨基酸序列，输出为溶解性标签，可定义为二分类（可溶/不可溶）。

数据集加载

在本任务中，数据集已经事先准备并划分完毕，提供了标准化接口 [cite: 1258, 1259]：

```
from solubilitydataset import ProteinSolubilityLMDBDataset

# lmbd_path 为数据路径
ds_train, ds_valid, ds_test = ProteinSolubilityLMDBDataset.load(lmbd_path)
```

每个数据样本包含 sequence 与对应的溶解性 label，数据形式划分为 training, valid, test。

模型与特征提取

ESM 是基于 Transformer 的蛋白语言模型，可通过预训练建模氨基酸序列中的上下文关系。使用时，可直接从 `/vepfs/problem2/ESM-checkpoint/` 加载我们提供的 ESM 模型权重，并通过自带的 `alphabet` 对象获得 `tokenizer` 与批转换器 (`batch_converter`)。后者可将蛋白序列列表转换为可直接输入模型的 token 张量。

微调流程：需调用 ESM-100 的序列编码器，将每个蛋白序列转化为隐藏表示，再通过池化层（如 mean-pool 或 [CLS] 表征）获得全局序列特征，输入到一个轻量分类或者回归头中进行预测。

代码示例：加载模型

`ckpt_path` 为所需要 load 的文件路径，`esm_model` 为加载权重的模型，`alphabet` 为 esm-2 的词表：

Python

```
import esm
import torch
from pathlib import Path

# Load the checkpoint
data = torch.load(ckpt_path, map_location='cpu')
model_name = Path(ckpt_path).stem

# Build the model architecture based on the checkpoint info
esm_model, alphabet = esm.pretrained.load_model_and_alphabet_core(
    model_name, data, None
)
```

代码示例：数据格式转换与特征提取

Python

```
# 准备实例序列
data = [
    ("protein1", "MKTVRQERLKSIVRILERSKEPVSGAQ..."),
    ("protein2", "KALTARQQEVDLIRDHISQTGMPPTRA..."),
]

# 批处理转换
batch_converter = alphabet.get_batch_converter()
batch_labels, batch_strs, batch_tokens = batch_converter(data)

# 提取特征
# repr_layers=[30] 指定提取模型第30层的隐藏状态
```

```
result = esm_model(batch_tokens, repr_layers=[30], return_contacts=True)
token_representations = result["representations"][30]
```

`token_representations` 的形状为 `[batch_size, seq_len, hidden_dim]`，表示每个氨基酸的向量表征。通常在下游任务中，我们会对氨基酸表征进行平均池化或使用 `[CLS]` token 表征以获得整个序列的全局表示，再将其输入到分类或回归头中进行微调。

模型与微调设置要求

1. **输入层**：沿用 ESM-100M 的 tokenizer/embedding；**禁止改动词表**。
2. **表征汇聚（二选一）**：需在报告中说明并固定。
 - `[CLS]` 向量。
 - Meanpooling（对有效残基位求平均，脚本需自行编写）。
3. **任务头**：分类或回归头。
4. **优化器与调度**：建议 AdamW；warmup + 余弦/线性退火均可。
5. **(Optional) 混合精度**：
 - AMP 下作前向与反向（传播）。
 - Unscale 后再梯度裁剪。
 - 记录是否出现 inf/NaN。

评测指标：评测指标为二分类 **Accuracy**。

文件描述

本题使用到的主要文件及描述如下（均位于 `/vepfs-readonly/problem2` 目录下）：

1. `esm` repo：已经下载好，路径位于 `/vepfs-readonly/problem2/esm`。
2. `solubility_mutetest.lmdb`：数据文件夹。
3. `ESM-checkpoint/`：ESM 预训练模型权重。

提交内容

本题需要提交一个存储测试集结果的文件到 `/vepfs/problem2/` 目录下：

1. **结果文件**：需要提交如下格式的 json 文件，命名为 `test_result.json`。
 - `key` 为蛋白名称，可以从提供的 dataset 里获取该字段。
 - `fasta sequence` 为预测蛋白的氨基酸序列。
 - `pred Label` 是训练模型预测的溶解性。

JSON 格式示例：

JSON

```
{
  "name": "yourname",
  "test_result": {
    "protein_name": ["fasta sequence", "Pred Label"]
  }
}
```

2. **说明文档**：一份以 `README.md` 命名的说明文档，详解解题思路。
3. **代码**：本题使用到的所有代码文件。
4. **日志**：训练日志 `train.log`。